

Classificação de Doenças em Plantas com Transfer Learning

Disciplina: Tópicos Especiais em Inteligência Artificial e Aprendizado de Máquina

Estudante: Jeovane dos Santos, Quele Andrade, Luana Lima, Renatta Andrade

Curso: Bacharelado em Engenharia de Computação e Pós-graduação em Engenharia Elétrica e Computação

22 de julho de 2026

Sumário

- 1 Resumo
- 2 Introdução
 - Contextualização
- 3 Referencial Bibliográfico
- 4 Metodologia
 - Visão Geral
 - Dataset e Pré-processamento
 - Transfer Learning e Fine-Tuning
- Data Augmentation
- 5 Resultados
 - Métricas Gerais
 - Curvas de Treinamento
 - Desempenho por Classe
 - Matriz de Confusão
 - Comparação com a Literatura
- 6 Discussão e Conclusão
 - Discussão

Resumo

Este trabalho aplica **Transfer Learning** com a arquitetura **EfficientNetB0** para a classificação de doenças em folhas de plantas utilizando o dataset *PlantDoc*, disponível publicamente no Kaggle, composto por 2.569 imagens distribuídas em 30 classes representando 13 espécies de plantas saudáveis e doentes. O treinamento seguiu uma estratégia em **duas fases**: na primeira, a base EfficientNetB0 permaneceu congelada enquanto apenas a cabeça classificadora foi ajustada; na segunda fase (*fine-tuning*), as últimas 30 camadas da rede base foram descongeladas com taxa de aprendizado reduzida (LR/10) para refinamento dos pesos. O modelo alcançou acurácia de validação de **83,26%** e acurácia no conjunto de teste independente de **56,17%**, resultado condizente com a dificuldade inerente do dataset, cujas classes apresentam alta similaridade visual e poucas imagens por categoria — características conhecidas na literatura como desafios centrais do PlantDoc [1].

Palavras-Chave: Transfer Learning; EfficientNet; Classificação de Imagens; Doenças em Plantas; *Fine-Tuning*; PlantDoc.

Contextualização

A detecção precoce de doenças em plantas é um desafio crítico:

- Doenças foliares causam perdas significativas na produção agrícola mundial
- Diagnóstico visual manual é lento, caro e sujeito a erros humanos
- Redes neurais convolucionais permitem automatizar a identificação com alta escalabilidade

Problema

Como classificar automaticamente 30 categorias de doenças foliares em 13 espécies de plantas a partir de imagens, com dataset limitado?

Dataset: PlantDoc

- Kaggle: *andresmgs/plantdec*
- Fonte: Thapa et al. (2020)
- **2.569 imagens** no total
- **30 classes** (13 espécies)
- Formato YOLO: images/ + labels/
- Partições: train, valid, test

Exemplos do Dataset — PlantDoc

Amostras do conjunto de treino

Tomato leaf mosaic virus



Blueberry leaf



Tomato Early blight leaf



Tomato leaf



Corn rust leaf



Peach leaf



Blueberry leaf



Cherry leaf



Tomato leaf mosaic virus



grape leaf black rot



Tomato Early blight leaf



Apple leaf



Apple rust leaf




Raspberry leaf




Strawberry leaf



Squash Powdery mildew leaf




Referencial Bibliográfico



Referência	Objetivo	Base de Dados	Métricas (melhores)
Thapa et al. (2020) [1]	Propor o dataset PlantDoc e avaliar modelos de classificação de doenças em condições reais de campo	PlantDoc: 2.569 imgs, 13 espécies, 30 classes	Acurácia: 54,8% (VGG16)
Hughes & Salathé (2015) [2]	Criar dataset de referência PlantVillage em ambiente controlado e aplicar CNNs para classificação de doenças	PlantVillage: 54.306 imgs, 14 espécies, 26 doenças	Acurácia: 99,3% (GoogLeNet)
Tan & Le (2019) [3]	Propor família EfficientNet via <i>compound scaling</i> , melhorando eficiência e acurácia	ImageNet (1,2M imgs, 1000 classes)	Top-1: 84,3% (EfficientNetB7)
Mohanty et al. (2016) [4]	Avaliar CNNs com Transfer Learning para diagnóstico automático de doenças foliares	PlantVillage (sub-conjunto)	Acurácia: 99,35% (AlexNet)

Visão Geral da Metodologia

Pipeline geral




Configuração do modelo

- Base: EfficientNetB0 (ImageNet)
- Cabeça: GAP → BN → Drop(0.4) → Dense(256) → Drop(0.3) → Softmax(30)
- Loss: categorical_crossentropy

Treinamento

- Otimizador: Adam
- Batch size: 32
- Máx. épocas: 40
- Resolução: 224×224
- Callbacks: EarlyStopping, ReduceLROnPlateau, ModelCheckpoint

Distribuição das classes



Dataset e Pré-processamento

Origem e formato

- Dataset no formato **YOLO/Roboflow**: pasta `images/` com fotos e pasta `labels/` com arquivos `.txt`
- Cada linha do `.txt`:
`class_id x y w h`

Reorganização automática

Para cada imagem, lê o `.txt`, extrai o `class_id` dominante e copia a foto para `/data_cls/<classe>/.` Imagens sem anotação são ignoradas (11 no total).

Distribuição após reorganização

Conjunto	Imagens
Treino	1.843
Validação	460
Teste	235
Total utilizadas	2.538

Observação

Média de ≈ 77 imagens por classe — dataset reduzido, o que justifica o uso de Transfer Learning e Data Augmentation.

Transfer Learning em Duas Fases

O que é Transfer Learning?

Aproveitar pesos aprendidos em um grande dataset (ImageNet, 1,2M imagens) como ponto de partida. O EfficientNetB0 já “sabe” detectar bordas, texturas e padrões visuais gerais.

Fase 1 — Base congelada

- Pesos do EfficientNetB0: **congelados**
- Apenas a cabeça classificadora é treinada
- $LR = 10^{-3}$; épocas: **40**
- Resultado: **val_acc = 76,96%**

Fase 2 — Fine-Tuning

- Últimas **30 camadas** descongeladas
- Camadas anteriores: mantidas congeladas
- $LR = 10^{-4}$ ($10\times$ menor); épocas: **33**
- Resultado: **val_acc = 83,26%**

Parâmetros do modelo

Treináveis: 338.206 | Congelados: 4.052.131 | Total:
4.390.337

Data Augmentation

Por que aumentar os dados?

- Dataset pequeno: média de ≈ 77 imgs por classe
- Aumenta artificialmente a diversidade de treino
- Reduz overfitting — modelo não memoriza as imagens
- Embutido no modelo Keras (ativo apenas no treino)


Transformações aplicadas

- RandomFlip (horizontal e vertical)
- RandomRotation (± 20)
- RandomZoom ($\pm 15\%$)
- RandomContrast ($\pm 15\%$)
- RandomBrightness ($\pm 10\%$)

(veja o próximo slide)

Exemplos de augmentation gerados pelo notebook são exibidos no slide seguinte.

Data Augmentation — Exemplos



Original (esq.) e 4 versões com augmentation aleatório

Resultados: Desempenho Geral


Tabela: Resumo do desempenho por fase de treinamento

Fase	Épocas	Melhor val_acc	Acc. Teste	Loss Teste
Fase 1 — Base congelada	40	76,96%	—	—
Fase 2 — Fine-Tuning	33	83,26%	—	—
Modelo final (best ckpt)	—	83,26%	56,17%	1,7461

Gap validação vs. teste (≈ 27 pp)

As pastas data/ e test/ foram capturadas em condições distintas pelo Roboflow, gerando diferença de distribuição. Resultado típico reportado para o PlantDoc na literatura [1].

Resultados: Curvas de Treinamento




Acurácia e Loss — Treino vs. Validação. Linha verde = início do fine-tuning (época 41).

Resultados: Desempenho por Classe

Tabela: Métricas por classe — conjunto de teste (seleção)

Classe	Precision	Recall	F1-Score	Support
Strawberry leaf	0,89	1,00	0,94	8
Corn rust leaf	0,77	1,00	0,87	10
grape leaf black rot	0,82	0,82	0,82	11
Squash Powdery mildew leaf	0,83	0,71	0,77	7
Tomato leaf	1,00	0,67	0,80	6
Bell_pepper leaf spot	0,20	0,14	0,17	7
Corn Gray leaf spot	0,25	0,25	0,25	4
Tomato mold leaf	0,19	0,50	0,27	6
Tomato leaf yellow virus	0,00	0,00	0,00	10
Média ponderada	0,58	0,56	0,55	235

Resultados: Acurácia por Classe



Verde $\geq 75\%$ | Laranja 50–75% | Vermelho $< 50\%$

Resultados: Matriz de Confusão



Comparação com a Literatura

Tabela: Comparação de acurácia no conjunto de teste do PlantDoc

Trabalho	Modelo	Estratégia	Acurácia (teste)
Thapa et al. (2020) [1]	VGG16	Transfer Learning	54,8%
Thapa et al. (2020) [1]	InceptionV3	Transfer Learning	50,1%
Thapa et al. (2020) [1]	ResNet50	Transfer Learning	46,9%
Mohanty et al. (2016) [4]	AlexNet	Fine-Tuning (PlantVillage*)	99,4%*
Este trabalho	EfficientNetB0	TL + Fine-Tuning	56,17%
Este trabalho	EfficientNetB0	val. acc (data/)	83,26%

Nota

*Mohanty et al. usam o PlantVillage (ambiente controlado), não o PlantDoc. No PlantDoc, nosso modelo supera VGG16, InceptionV3 e ResNet50 dos autores originais do dataset.

Discussão e Conclusão

Pontos fortes

- EfficientNetB0 com TL supera os baselines do paper original do PlantDoc;
- Estratégia em 2 fases: ganho de ≈ 6 pp de val_acc (76,96% $\rightarrow$ 83,26%);
- Pipeline de reorganização automática adapta datasets YOLO para classificação.

Limitações

- Gap validação (83%) vs. teste (56%): diferença de distribuição entre partições;
- Dataset desbalanceado: classes com poucas amostras prejudicam o aprendizado;
- Alta similaridade visual entre as 8 classes de doenças de tomate dificulta a discriminação;
- *Tomato leaf yellow virus*: 0% de acerto no teste — possível

Trabalhos Futuros

Próximos passos

- Experimentar arquiteturas maiores: **EfficientNetB3/B5** ou **ResNet101**;
- Aplicar balanceamento de classes: *class weights* ou *oversampling* (SMOTE);
- Investigar **semi-supervised learning** para imagens não anotadas;
- Explorar **Grad-CAM** para visualizar as regiões da folha usadas na decisão;
- Coletar mais imagens das classes com baixo desempenho (*Tomato leaf yellow virus*, *Bell_pepper leaf spot*).

Referências I

- [1] Rashmi Thapa et al. “The PlantDoc Dataset: A Dataset for Visual Plant Disease Detection”. Em: **Proceedings of the 7th ACM IKDD CoDS and 25th COMAD**. 2020, pp. 249–253. DOI: 10.1145/3371158.3371196.
- [2] David P. Hughes e Marcel Salathé. “An open access repository of images on plant health to enable the development of mobile disease diagnostics”. Em: **arXiv preprint arXiv:1511.08060**. 2015.
- [3] Mingxing Tan e Quoc V. Le. “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks”. Em: **Proceedings of the 36th International Conference on Machine Learning (ICML)**. 2019, pp. 6105–6114.
- [4] Sharada P. Mohanty, David P. Hughes e Marcel Salathé. “Using Deep Learning for Image-Based Plant Disease Detection”. Em: **Frontiers in Plant Science** 7 (2016), p. 1419. DOI: 10.3389/fpls.2016.01419.

Obrigado(a) pela Atenção!