

Detecção de Desmatamento com Redes Neurais Convolucionais

Classificação Binária de Imagens de Satélite: *desmatado* vs.
preservado

Disciplina: Aprendizado de Máquina - Mestrado e Tópicos Especiais em Inteligência Artificial e Aprendizado de Máquina - Graduação

Estudante: Jeovane dos Santos, Quele Andrade, Luana Lima, Renatta Andrade

Curso: Bacharelado em Engenharia de Computação e Pós-graduação em Engenharia Elétrica e Computação

Sumário

1 Resumo

2 Introdução

- Contextualização
- Trabalhos Relacionados

3 Metodologia

- Visão Geral
- Pré-processamento e Augmentation

■ Modelo

4 Resultados

- Métricas
- Matriz de Confusão

5 Discussão

- Discussão

6 Conclusão

- Conclusão

Resumo

O desmatamento ameaça ecossistemas críticos como a Amazônia, responsável por 40% das florestas tropicais do planeta. Este trabalho propõe um pipeline de classificação binária de imagens satelitais (desmatado vs. preservado) com ResNet-50 via Transfer Learning em duas etapas, Data Augmentation e BinaryFocalCrossentropy para lidar com classes desbalanceadas e escassez de dados. Com apenas 130 imagens, o modelo atingiu AUC-ROC de 0,9773, F1-score macro de 0,92 no conjunto de teste, demonstrando a viabilidade da abordagem proposta mesmo sob severas restrições de volume de dados.

Palavras-Chave: Desmatamento; CNN; Transfer Learning; ResNet-50; Focal Loss; Monitoramento Ambiental.

Contextualização

O desmatamento é um dos maiores desafios ambientais globais:

- A Floresta Amazônica representa **40% das florestas tropicais** do planeta [1]
- O monitoramento manual é **lento e custoso**
- Imagens de satélite tornam possível o monitoramento em escala

Problema

Como identificar automaticamente áreas desmatadas a partir de imagens satelitais com poucos dados disponíveis?

Dataset utilizado


- Kaggle: *Deforestation / Non-Deforestation Area Analysis*
- **130 imagens** no total
- 77 de desmatamento
- 53 sem desmatamento
- Classes desbalanceadas

Trabalhos Relacionados

- **Dastour & Hassan (2023)** compararam ResNet-50, EfficientNetV2-B0 e ResNet-152 para classificação de imagens de sensoriamento remoto — ResNet-50 atingiu **F1 = 0,967** no conjunto de teste [2]
- **Al-Dabbagh et al. (2024)** — revisão sistemática mostrando que **U-Net + ResNet-50 (backbone)** alcançou acurácia de 99,91% na detecção de desmatamento por segmentação semântica [3]
- **Bayrak & Demiray (2024)** avaliaram CNNs pré-treinadas (ResNet, DenseNet, EfficientNet) para monitoramento de desmatamento — queda de apenas **10% na acurácia** ao transferir de dados tropicais para temperados [4]

Visão Geral da Metodologia

Pipeline



Dataset após split

- Treino: **103 imagens**
- Teste: **27 imagens**

Configuração

- Imagem: 224×224 px
- Batch size: 16
- Otimizador: Adam
- Loss: BinaryFocalCrossentropy

Pré-processamento e Data Augmentation

Por que usar Data Augmentation?

- Com apenas 103 imagens de treino, o modelo tenderia a **decorar** os dados em vez de generalizar
- Augmentation gera versões modificadas de cada imagem a cada época, forçando o modelo a aprender características mais robustas

Transformações aplicadas (treino)

- Rotação até 60°
- Flip horizontal e vertical
- Zoom in/out ($\pm 40\%$)
- Variação de brilho ($\pm 50\%$)
- Deslocamento e distorção (*shear*)

Observação importante

O número de imagens no disco **não muda** — continuam sendo 103. O que muda é que o modelo nunca vê a mesma imagem igual duas vezes, artificialmente aumentando a diversidade do treino.

Modelo: ResNet-50 com Transfer Learning



Por que Transfer Learning?

- Com apenas 103 imagens, treinar uma CNN do zero é **inviável**
- ResNet-50 pré-treinado no ImageNet já conhece bordas, texturas e formas genéricas
- Precisamos apenas adaptar o topo da rede para o domínio de satélite

Estratégia de dois estágios

Stage 1 — Cabeça ($LR = 10^{-3}$)

- Backbone totalmente congelado
- Treina apenas as camadas Dense adicionadas
- Estabiliza os pesos antes do fine-tuning

Stage 2 — Fine-tuning ($LR = 10^{-6}$)

- Descongela blocos conv4 + conv5
- LR muito baixo para não destruir os pesos do ImageNet
- Adapta o backbone ao domínio específico

Função de Perda: BinaryFocalCrossentropy

Motivação

- Dataset desbalanceado: 77 vs 53 imagens
- CrossEntropy padrão levou o modelo a prever sempre a mesma classe

Configuração

- `gamma=2.0` — foco nos erros difíceis
- `apply_class_balancing=True` — peso automático entre classes
- Nativa no Keras desde TF 2.9

Resultados: Métricas no Conjunto de Teste



ResNet-50 — Conjunto de Teste (22 imagens)

Métrica	Deforest.	No Defor.
Precision	0,89	1,00
Recall	1,00	0,82
F1-Score	0,94	0,90
Acurácia	0,93	
AUC-ROC	0,9773	
F1 macro avg	0,92	

Por que AUC-ROC como métrica principal?

Com dataset desbalanceado, a acurácia pode enganar — um modelo que prevê sempre a classe majoritária pode ter acurácia alta. O **AUC-ROC** e o **F1-score** são métricas mais confiáveis nesses casos.

Referência da literatura


Dastour & Hassan (2023): ResNet-50 atingiu **F1 = 0,967** em sensoriamento remoto com dataset maior [2].

Resultados

Tabela: Comparação com trabalhos relacionados

Trabalho	Método	Métrica	Valor
Dastour & Hassan (2023)	ResNet-50 + TL	F1-score	0,967
Al-Dabbagh et al. (2024)	U-Net + ResNet-50	Acurácia	99,91%
Bayrak & Demiray (2024)	CNNs pré-treinadas	Δ Acurácia	−10%
Este trabalho	ResNet-50 + TL	F1 / AUC-ROC	0,92 / 0,9773

Análise dos Erros — Matriz de Confusão



Matriz de Confusão no conjunto de teste

Discussão

Pontos fortes

- Transfer Learning com ResNet-50 viabilizou resultados expressivos com apenas 104 imagens de treino
- Data Augmentation agressiva foi essencial para reduzir overfitting
- BinaryFocalCrossentropy resolveu o problema de desbalanceamento sem necessidade de class_weight manual

Limitações

- Dataset com **apenas 130 imagens** — métricas com alta variância estatística
- Com 27 imagens de teste, 2 erro a mais ou a menos muda o F1 em ± 5 pontos percentuais
- Curvas de aprendizado oscilatórias dificultam interpretação visual da convergência

Conclusão

- Foi implementado um pipeline completo de **classificação de desmatamento** com ResNet-50 via Transfer Learning em duas etapas (head + fine-tuning)
- Com apenas **130 imagens**, o modelo atingiu **AUC-ROC = 0,9773**, **F1-score = 0,94-0,90** e **acurácia = 93%** no conjunto de teste
- As estratégias de **Data Augmentation** e **BinaryFocalCrossentropy** foram determinantes para contornar as limitações de volume e desbalanceamento do dataset
- Os resultados são consistentes com a literatura, considerando o contexto de dataset reduzido [2, 4]
- A abordagem de *patch classification* é válida como passo inicial; **segmentação semântica** deve ser explorada para maior precisão operacional [3]

Referências I

- [1] SpaceVision4Amazon Team. “CVPR MultiEarth 2023 Deforestation Estimation Challenge: SpaceVision4Amazon”. Em: **arXiv preprint** (2023). arXiv:2307.04715.
- [2] Hatef Dastour e Quazi K. Hassan. “A Comparison of Deep Transfer Learning Methods for Remote Sensing Scene Classification”. Em: **Sustainability** 15.7 (2023), p. 7854. DOI: 10.3390/su15107854.
- [3] Ali Mohsin Al-Dabbagh, Nasru Minallah, Adnan Zeb et al. “Deforestation Detection Using Deep Learning-Based Semantic Segmentation Techniques: A Systematic Review”. Em: **Frontiers in Forests and Global Change** 7 (2024). DOI: 10.3389/ffgc.2024.1300060.
- [4] Begüm Bayrak e Buse Cennet Demiray. “Applicability of Pre-Trained CNNs in Temperate Deforestation Detection”. Em: **European Journal of Remote Sensing** (2024). DOI: 10.1080/22797254.2024.2367221.

Obrigado(a) pela Atenção!

Código disponível em:

`github.com/queleandrade/
Aprendizado-de-Maquina---Mestrado`