

Técnicas de discretização para previsão da velocidade do vento usando RNAs

Projeto Mucuri

Discentes: Gleice Souza; Lucas Batista; Matheus Mendes

Professor: Dr. Tiago Palma Pagano

Cursos:

Bacharelado em Engenharia de Computação

Mestrado em Engenharia Elétrica e Computação

Disciplinas:

Aprendizado de Máquina

Tópicos especiais em Inteligência Artificial

27 de maio de 2026

Sumário

- 1 Introdução
- 2 Trabalhos relacionados
- 3 Metodologia
- 4 Resultados

- 5 Conclusão
 - Considerações finais
 - Trabalhos futuros
- 6 Agradecimentos

Contexto e Motivação

- Crescimento da energia eólica impulsionado pela transição energética e descarbonização.
- A velocidade do vento apresenta alta variabilidade temporal, dificultando previsões precisas.
- Dados meteorológicos reais possuem ruídos, lacunas e outliers que afetam o desempenho dos modelos.
- Técnicas de pré-processamento e representação temporal podem melhorar a qualidade das previsões.

Problema e Objetivos

Problema:

Pergunta Central

Qual o impacto do pré-processamento e da representação temporal no desempenho de Redes Neurais Artificiais para previsão da velocidade do vento?

Objetivos:

- Avaliar estratégias de pré-processamento e representação temporal.
- Comparar diferentes abordagens de engenharia de atributos.
- Avaliar o desempenho preditivo dos modelos utilizando métricas estatísticas.

Trabalhos relacionados

Previsão da velocidade do vento a curto prazo usando redes neurais artificiais em Mucuri, Bahia [1]

- **Objetivo:** Desenvolver modelos com diferentes arquiteturas de Redes Neurais Artificiais para identificar a mais eficiente na previsão da velocidade do vento em curto prazo (1 hora) na cidade de Mucuri–BA.
- **Modelo:** MLP (Multilayer Perceptron) com algoritmo Feed-forward Backpropagation.
- **Arquiteturas:**
 - RNA com 3 camadas: 9 entradas + {9, 6, 3, 1} neurônios na camada oculta + 1 saída.
 - RNA com 4 camadas: 9 entradas + {9,6}, {6,3}, {1,1} neurônios nas camadas ocultas + 1 saída.

Trabalhos relacionados

Predição de séries temporais da velocidade do vento no Brasil [2]

- **Objetivo:** Desenvolver modelos para prever a velocidade do vento, visando estimar a disponibilidade de energia eólica nas regiões estudadas.
- **Modelo:** MLP / Redes Neurais Artificiais Deep Feedforward (DFF).
- **Arquiteturas:** Foram aplicadas duas abordagens principais de redes profundas no trabalho:
 - Deep Feedforward (DFF): Modelo de rede direta (variação profunda da MLP), otimizado com a função de ativação ReLU e o algoritmo Adam.
 - Long Short Term Memory (LSTM): Modelo de rede recorrente focado em séries temporais, otimizado com a função Tangente Hiperbólica (tanh) e o algoritmo RMSprop.

Trabalhos relacionados

Comparação Entre Modelos Estatísticos e Redes Neurais Usando Persistência como Referência para a Previsão da Velocidade do Vento [3]

- **Objetivo:** Comparar o desempenho de Redes Neurais Artificiais e modelos estocásticos na previsão da velocidade do vento (de 1h a 48h à frente).
- **Modelo:** Redes Neurais Artificiais do tipo Feedforward (FTDNN).
- **Arquiteturas:** O estudo utilizou duas arquiteturas de redes neurais baseadas em tempo:
 - FTDNN (Focused Time-Delay Neural Network): Rede MLP direta (feedforward) adaptada com memória de atraso temporal estritamente na camada de entrada.
 - NARX (Nonlinear Autoregressive with Exogenous Inputs): Rede recorrente que realimenta o modelo com os seus próprios valores previstos anteriormente.

Metodologia

- 1 Curadoria e Pré-processamento dos Dados
- 2 Treinamento
- 3 Avaliação de Desempenho



Curadoria e Pré-processamento dos Dados



■ Descrição do dataset

- Mucuri
- 945 registros e 9 atributos
 - **Entrada:** dia, mês, ano, hora, velocidade média horária do vento, direção média horária do vento, temperatura média horária, umidade média horária e pressão média horária
 - **Saída:** velocidade horária do vento
- 30/11/2015 às 14h até 08/01/2016 às 22h

Curadoria e Pré-processamento dos Dados



■ Pré-processamento dos dados

- Filtragem para apenas os dados de 2015
- 754 registros e 9 atributos
- Normalização Min-Max de 0 a 1
- Período utilizado
 - Experimento: 30/11/2015 às 14h até 31/12/2015 às 13h
 - Treinamento, validação e teste: 30/11/2015 às 14h até 23/12/2015 às 11h
 - Previsão: 23/12/2015 às 12h até 31/12/2015 às 13h
- Divisão dos dados
 - 70% para treino
 - 15% para validação
 - 15% para teste

Treinamento




Figura 1: Arquitetura da MLP

Treinamento

■ Hiperparâmetros

- Épocas: 200
- Taxa de Aprendizado: 0.001
- Otimizador: Adam
- Funções de ativação: ReLU e linear

■ Monitoramento

- EarlyStopping
- ModelCheckpoint

■ Experimentos

- Janelamento (1 até 10)
- Discretização
- Discretização trigonométrica



Janelamento (N = 3)




Figura 2: Arquitetura da MLP para o janelamento com N = 3

Discretização




Figura 3: Arquitetura da MLP para a discretização

Discretização trigonométrica




Figura 4: Arquitetura da MLP para a discretização trigonométrica

Métricas de Erro

- **MSE (*Mean Squared Error*)**: mede a média dos erros quadráticos entre os valores previstos e os valores reais. Penaliza mais fortemente erros maiores.
- **MAE (*Mean Absolute Error*)**: calcula a média dos erros absolutos entre previsões e valores reais, fornecendo uma medida mais interpretável do erro médio.
- **RMSE (*Root Mean Squared Error*)**: representa a raiz quadrada do MSE, expressando o erro médio na mesma unidade dos dados originais.

Métricas de Ajuste e Correlação

- **R^2 (Coeficiente de Determinação):** indica a proporção da variabilidade dos dados explicada pelo modelo. Valores mais próximos de 1 representam melhor ajuste.
- **R (Coeficiente de Correlação de Pearson):** mede a intensidade e a direção da relação linear entre valores previstos e reais. Valores próximos de 1 indicam forte correlação positiva.

Janelamento ($n=3$)




Figura 5: Evolução da função de perda durante o treinamento do modelo com janelamento ($n = 3$).

Discretização




Figura 6: Evolução da função de perda durante o treinamento do modelo com discretização simples.

Discretização trigonométrica




Figura 7: Evolução da função de perda durante o treinamento do modelo com discretização trigonométrica.

Comparativo entre as técnicas




Figura 8: Comparação das séries reais e previstas no bloco de teste entre as técnicas avaliadas.

Comparativo entre as técnicas




Figura 9: Comparação das séries reais e previstas no bloco de previsão entre as técnicas avaliadas.

Resultados – Bloco de Treino

Métrica	Disc. simples	Disc. trig.	Jan. ($n = 3$)
MAE	0.890111	0.813668	0.817964
MSE	1.285049	1.129012	1.125625
RMSE	1.133600	1.062550	1.060955
Erro mín.	0.000569	0.003402	0.001306
Erro máx.	4.283808	3.962738	4.477371
r	0.908815	0.922090	0.918410
R^2	0.818286	0.840351	0.839417
Amostras	384	384	382
Épocas	117	68	79

Tabela 1: Resultados do bloco de treino para as técnicas de discretização simples, discretização trigonométrica e melhor janelamento ($n = 3$). A discretização trigonométrica apresentou os menores valores de erro e o maior coeficiente de determinação neste conjunto.

Resultados – Bloco de Validação

Métrica	Disc. simples	Disc. trig.	Jan. ($n = 3$)
MAE	0.820437	0.650804	0.874566
MSE	1.020186	0.675925	1.241600
RMSE	1.010043	0.822147	1.114271
Erro mín.	0.000341	0.024859	0.004312
Erro máx.	3.012764	2.319788	3.454337
r	0.905967	0.941134	0.899176
R^2	0.819791	0.880602	0.780680
Amostras	82	82	82
Épocas	117	68	79

Tabela 2: Resultados do bloco de validação para as técnicas avaliadas. A discretização trigonométrica obteve o melhor desempenho geral, com menores métricas de erro e maior valor de R^2 .

Resultados – Bloco de Teste

Métrica	Disc. simples	Disc. trig.	Jan. ($n = 3$)
MAE	0.815992	0.677972	0.749670
MSE	1.132042	0.774442	0.858946
RMSE	1.063975	0.880024	0.926793
Erro mín.	0.012727	0.006225	0.030871
Erro máx.	2.638039	2.274665	2.712753
r	0.938259	0.963685	0.957867
R^2	0.862692	0.906066	0.895816
Amostras	83	83	83
Épocas	117	68	79

Tabela 3: Resultados do bloco de teste para as diferentes técnicas de modelagem. A discretização trigonométrica apresentou o melhor desempenho global, alcançando os menores erros e maior correlação entre valores reais e preditos.

Resultados – Bloco de Previsão

Métrica	Disc. simples	Disc. trig.	Jan. ($n = 3$)
MAE	0.872704	0.748371	0.826727
MSE	1.234862	0.897506	1.131014
RMSE	1.111243	0.947368	1.063491
Erro mín.	0.000432	0.016447	0.003822
Erro máx.	4.335750	3.521947	4.577920
r	0.911340	0.937950	0.925299
R^2	0.830509	0.876813	0.844763
Amostras	194	194	194
Épocas	117	68	79

Tabela 4: Resultados do bloco de previsão para as técnicas comparadas. A discretização trigonométrica apresentou o menor erro quadrático médio e o maior coeficiente de determinação entre os métodos avaliados.

Comparação com resultados da literatura

Bloco	Métrica	Artigo [1]	Disc. simples	Disc. trig.	Jan. ($n = 3$)
Treino	r	0.948730	0.908815	0.922090	0.918410
	MSE	0.944000	1.285049	1.129012	1.125625
Validação	r	0.905210	0.905967	0.941134	0.899176
	MSE	1.413000	1.020186	0.675925	1.241600
Teste	r	0.909830	0.938259	0.963685	0.957867
	MSE	—	1.132042	0.774442	0.858946
Previsão	MAE	0.778210	0.872704	0.748371	0.826727
	MSE	0.999750	1.234862	0.897506	1.131014
	Erro mín.	0.003960	0.000432	0.016447	0.003822
	Erro máx.	3.056020	4.335750	3.521947	4.577920
	r	0.935460	0.911340	0.937950	0.925299
	R^2	0.994740	0.830509	0.876813	0.844763

Tabela 5: Comparação entre os resultados deste trabalho e os resultados apresentados por Zucatelli et al. (2018) para treino, teste e previsão da velocidade do vento.

Considerações finais


- Estratégias de pré-processamento e representação temporal influenciaram diretamente o desempenho das RNAs.
- A discretização trigonométrica apresentou melhor desempenho e maior capacidade de generalização.
- Obteve os menores erros ($MAE = 0.748$; $MSE = 0.897$) e maior correlação ($r = 0.938$).
- Em comparação com Zucatelli et al. (2018), apresentou melhorias nas principais métricas.

Trabalhos futuros

- Avaliar modelos recorrentes (LSTM e GRU).
- Incorporar novas variáveis meteorológicas.
- Aplicar otimização automática de hiperparâmetros.
- Validar o modelo em diferentes regiões.



Referências

- 
- [1] Pedro Zucatelli et al. “Previsão da velocidade do vento a curto prazo usando redes neurais artificiais em Mucuri, Bahia”. Em: **X Congresso Nacional de Engenharia Mecânica, Salvador-Bahia**. ABCM, 2018. DOI: [doi://10.26678/ABCM.CONEM2018.CON18-0393](https://doi.org/10.26678/ABCM.CONEM2018.CON18-0393).
- [2] Yann Fabricio Cardoso de FIGUEIREDO et al. “Predição de séries temporais da velocidade do vento no Brasil”. Em: (2021).
- [3] Erick C. Bezerra et al. “Comparação Entre Modelos Estatísticos e Redes Neurais Usando Persistência como Referência para a Previsão da Velocidade do Vento”. Em: **X SBAt-Simpósio Brasileiro de Automação Inteligente, Sao Joao del Rei-MG** 10 (2011), pp. 369–374.

Gratos pela atenção!

