

Segmentação Comportamental de Clientes usando Dados Transacionais do Dunnhumby

Discentes: Gleice Souza; Lucas Batista; Matheus Mendes

Professor: Dr. Tiago Palma Pagano

Cursos:

Bacharelado em Engenharia de Computação

Mestrado em Engenharia Elétrica e Computação

Disciplinas:

Aprendizado de Máquina

Tópicos especiais em Inteligência Artificial

Sumário

- 1 **Resumo**
- 2 **Introdução**
 - Contextualização
 - Justificativa
 - Problema
 - Objetivos
- 3 **Trabalhos relacionados**
- 4 **Metodologia**
 - Curadoria e Integração dos Dados
- Engenharia de Atributos Comportamentais
- Padronização dos Dados
- Redução de Dimensionalidade com PCA
- Clusterização com K-Means
- Avaliação dos Clusters
- 5 **Resultados**
- 6 **Conclusão**
 - Considerações finais
 - Trabalhos futuros
- 7 **Agradecimentos**

Resumo

Este trabalho apresenta uma abordagem de segmentação comportamental de clientes no varejo supermercadista, fundamentada em dados transacionais do dataset *Dunnhumby – The Complete Journey*. A partir da construção de atributos relacionados à recência, frequência, gasto total e percentual de desconto, busca-se caracterizar padrões de consumo e identificar grupos de clientes com comportamentos semelhantes. Para isso, foram aplicadas etapas de engenharia de atributos, padronização dos dados, redução de dimensionalidade por meio da PCA e clusterização com o algoritmo K-Means. Os resultados obtidos evidenciam três perfis principais de consumidores: clientes ocasionais ou em risco, clientes fiéis de alto valor e clientes VIP. Dessa forma, a segmentação proposta contribui para a definição de estratégias de marketing mais precisas, orientadas à reativação, à fidelização e à personalização do relacionamento com clientes de maior valor estratégico.

Palavras-chave: segmentação de clientes; estratégias de marketing; aprendizado de máquina não supervisionado; K-Means; PCA.

Contextualização

- O varejo supermercadista gera grandes volumes de dados provenientes das transações de compra.
- Esses dados permitem compreender o comportamento e o perfil dos clientes.
- Indicadores como recência, frequência, gasto total e percentual de desconto auxiliam na caracterização dos consumidores.
- Técnicas de Ciência de Dados possibilitam transformar esses dados em informações úteis para a tomada de decisão.

Justificativa

- A segmentação de clientes permite direcionar ações de marketing de forma mais eficiente.
- Reduz a utilização de estratégias genéricas (*one-size-fits-all*).
- Possibilita identificar clientes de maior valor e clientes com risco de abandono.
- Apóia decisões baseadas em dados, contribuindo para retenção, fidelização e aumento da receita.

Problema de Pesquisa

Problema

Como segmentar clientes de um supermercado a partir de dados transacionais, utilizando técnicas de redução de dimensionalidade e clusterização para apoiar estratégias de marketing?

Objetivos

Objetivo geral

- Segmentar clientes de um supermercado utilizando variáveis comportamentais, redução de dimensionalidade por PCA e clusterização com K-Means.

Objetivos específicos

- Consolidar os dados no nível de cliente;
- Aplicar algoritmo de clusterização;
- Interpretar os perfis dos clientes e propor estratégias de marketing.

Trabalhos relacionados

Avaliação de métodos de clustering para a segmentação geográfica de clientes [1]

- Avalia métodos de clustering (K-Means, K-Means++, SVM) para segmentação geográfica.
- K-Means apresentou melhor desempenho, reduzindo distâncias de atendimento e melhorando a distribuição de clientes.

Trabalhos relacionados

Aplicação da Clusterização por K-means para Criação de Sistema de Recomendação de Produtos baseado em Perfis de Compra [2]

- Propõe um sistema de recomendação de produtos baseado na clusterização de clientes por meio do algoritmo K-Means.
- Os clusters identificados permitiram recomendar produtos a clientes com perfis de compra semelhantes, apoiando estratégias de vendas e marketing.

Curadoria e Integração dos Dados

■ Dataset

- Dunnhumby – The Complete Journey
- Disponibilizado na plataforma Kaggle
- Bases utilizadas:
 - `transaction_data.csv`
 - `product.csv`

■ Integração das bases

- Junção dos arquivos por meio do atributo `PRODUCT_ID`
- Geração de uma base consolidada contendo transações e informações dos produtos
- Agrupamento das informações por cliente (`household_key`)

Engenharia de Atributos Comportamentais

Foram construídas variáveis para representar o comportamento de compra dos consumidores.

■ Recência

- Número de dias desde a última compra
- Calculada pela diferença entre o último dia do conjunto de dados e a última compra do cliente

■ Frequência

- Quantidade de cestas de compras distintas (BASKET_ID)

■ Gasto Total

- Soma de SALES_VALUE por cliente

■ Percentual de Desconto

- Relação entre descontos recebidos (RETAIL_DISC) e gasto total
- Utilizado como indicador de sensibilidade a promoções

Padronização dos Dados



- Variáveis utilizadas na clusterização:
 - Recência
 - Frequência
 - Gasto Total
 - Percentual de Desconto
- Aplicação do **StandardScaler**
- Transformação dos atributos para:
 - Média igual a 0
 - Desvio padrão igual a 1
- Necessária devido à sensibilidade do algoritmo K-Means às diferentes escalas dos atributos.

Redução de Dimensionalidade com PCA

- Aplicação da Análise de Componentes Principais (PCA)
- Redução dos quatro atributos comportamentais para duas componentes principais
- Objetivo:
 - Facilitar a visualização gráfica dos clientes
 - Permitir a projeção dos clusters em um espaço bidimensional
- O PCA não foi utilizado para o treinamento do K-Means
- O agrupamento foi realizado utilizando os dados padronizados originais

Clusterização com K-Means



- Algoritmo não supervisionado K-Means
- Inicialização:
 - `random_state = 42`
 - `n_init = 10`
- Determinação do número de clusters por meio do:
 - Método do Cotovelo
 - Avaliação dos valores de $K = 1$ até $K = 7$

Avaliação dos Clusters

■ Métrica quantitativa

- Silhouette Score
- Avalia simultaneamente:
 - Coesão interna dos grupos
 - Separação entre os clusters

■ Análise visual

- Projeção bidimensional utilizando PCA
- Visualização dos centroides dos clusters

■ Interpretação dos perfis

- Cálculo dos valores médios das variáveis em cada cluster
- Identificação de perfis de comportamento de compra
- Definição de possíveis ações de marketing segmentadas

Gráfico do método do cotovelo



Método do Cotovelo - K-Means nos dados normalizados




Figura 1: Evolução da inércia em função dos valores de K.

Agrupamento realizado

Segmentação de Clientes dunnhumby - K-Means + Visualização PCA





Figura 2: Visualização dos clusters obtidos para K = 3.

Distribuição de clientes por cluster



Perfil dos clientes




Figura 4: Comparação das características médias dos clusters.

Avaliação do agrupamento

- **Índice de Silhouette:** 0,448, indicando separação moderada entre os grupos.
- **Variância explicada pela PCA:**
 - PC1: 46,63%;
 - PC2: 24,62%;
 - variância acumulada: 71,24%.

Comparação com a literatura

O Índice de Silhouette obtido (**0,448**) é ligeiramente superior aos valores reportados por [1], que variaram entre **0,308 e 0,439**.

Interpretação dos clusters

Cluster	Recência	Frequência	Gasto total	Desconto (%)	Perfil
0	317,81	23,64	569,32	20,00	Ocasionais ou em risco
1	19,45	76,03	2119,49	19,00	Fiéis de alto valor
2	3,69	286,47	8817,52	16,00	VIP

Tabela 1: Perfil médio dos clientes em cada cluster para $K = 3$.

A interpretação dos grupos foi realizada com base nas variáveis de recência, frequência, gasto total e percentual de desconto.

Cluster 0 — Clientes ocasionais ou em risco

- O grupo apresenta **baixa atividade** e reduzido relacionamento com a empresa.
- Suas principais características são:
 - maior recência média, indicando um longo período sem compras;
 - baixa frequência de compra;
 - menor gasto total médio entre os grupos.
- Esse comportamento indica maior risco de abandono e necessidade de reaproximação.

Estratégia recomendada: desenvolver campanhas de reativação, cupons de retorno, lembretes personalizados e incentivos para novas compras.

Cluster 1 — Clientes fiéis de alto valor

- O grupo concentra clientes **frequentes, recentes e financeiramente relevantes**.
- Destacam-se:
 - baixa recência média, associada a compras recentes;
 - alta frequência de compra;
 - elevado gasto total médio.
- Trata-se de um segmento consolidado, cuja retenção contribui diretamente para a manutenção do faturamento.

Estratégia recomendada: investir em programas de fidelidade, ofertas personalizadas, benefícios exclusivos e ações de retenção.

Cluster 2 — Clientes VIP

- O grupo reúne os clientes **mais valiosos da base**.
- Seus principais atributos são:
 - menor recência média, indicando compras muito recentes;
 - maior frequência de compra;
 - maior gasto total médio.
- Mesmo recebendo descontos ligeiramente menores, esses clientes mantêm elevado volume de compras, indicando fidelização além de incentivos promocionais.

Estratégia recomendada: priorizar atendimento diferenciado, retenção premium, benefícios exclusivos e manutenção do relacionamento.

Síntese dos perfis

Cluster	Perfil identificado	Estratégia prioritária
0	Clientes ocasionais ou em risco	Reativação e recuperação
1	Clientes fiéis de alto valor	Retenção e fidelização
2	Clientes VIP	Relacionamento e benefícios premium

Tabela 2: Síntese dos perfis identificados e das estratégias recomendadas.

Conclusão

Os resultados indicam três níveis distintos de relacionamento: clientes que precisam ser reativados, clientes recorrentes que devem ser retidos e clientes VIP que exigem tratamento prioritário.

Considerações finais

- A aplicação do algoritmo K-Means permitiu identificar três perfis distintos de clientes, evidenciando diferentes padrões de comportamento de compra.
- A segmentação obtida facilita a definição de estratégias específicas para cada grupo, tornando as ações de marketing mais direcionadas.
- Os resultados indicam oportunidades para:
 - reativar clientes pouco ativos;
 - fortalecer a fidelização de clientes recorrentes;
 - preservar o relacionamento com os clientes de maior valor.

Trabalhos futuros

- Incorporar outras variáveis;
- Utilizar outras tabelas do dataset;
- Avaliar outros algoritmos de clusterização;
- Comparar diferentes técnicas de redução de dimensionalidade;
- Empregar métricas adicionais para validar a qualidade dos agrupamentos.

Referências

- [1] Guilherme Kauer De Nadal. **Avaliação de métodos de clustering para a segmentação geográfica de clientes**. 2023.
URL: <https://lume.ufrgs.br/handle/10183/262175>.
- [2] Roniel Venâncio Alencar Santana e Heráclito Lopes Jaguaribe Pontes. “Aplicação da clusterização por K-means para criação de sistema de recomendação de produtos baseado em perfis de compra”. Em: **Navus** 10 (2020), pp. 1–14. URL: <https://dialnet.unirioja.es/servlet/articulo?codigo=7774814>.

Gratos pela atenção!

