

Previsão de Preços de Gasolina com Redes Neurais MLP

Disciplina: Tópicos Especiais em Inteligência Artificial e Aprendizado de Máquina - Graduação

Estudante: Jeovane dos Santos, Quele Andrade, Luana Lima, Renatta Andrade

Curso: Bacharelado em Engenharia de Computação e Pós-graduação em Engenharia Elétrica e Computação

22 de julho de 2026

Sumário

- 1 Resumo
- 2 Introdução
 - Contextualização
- 3 Referencial Bibliográfico
- 4 Metodologia
 - Visão Geral
- 5 Estratégias de Representação Temporal
 - Janelamento
- 5 Resultados
 - Métricas
 - Gráficos
- 6 Discussão e Conclusão
 - Discussão

Resumo

Este trabalho aplica redes neurais do tipo MLP (*Multilayer Perceptron*) para a tarefa de regressão em séries temporais de preços de gasolina comum no Brasil. Foram investigadas três estratégias de representação temporal dos dados: **discretização numérica** (ano e mês como inteiros), **codificação trigonométrica** (seno de ano e mês) e **janelamento** com $n = 2$ e $n = 4$ passos anteriores. O dataset utilizado é público no Kaggle (*combustiveis-brasil*), com dados mensais de preço médio de revenda. Os modelos foram avaliados por MSE, MAE e R^2 , permitindo comparação direta entre as abordagens.

Palavras-Chave: MLP; Regressão; Séries Temporais; Janelamento; Gasolina; Transfer Learning Temporal.

Contextualização

Previsão de preços de combustíveis é um problema relevante:

- Preços de gasolina afetam diretamente o custo de vida e a inflação
- Dados históricos mensais permitem modelagem como **série temporal**
- Redes MLP são capazes de capturar padrões não-lineares nos dados

Problema

Como representar o tempo de forma eficaz para que uma MLP consiga prever o preço do próximo mês?

Dataset utilizado


- Kaggle: *combustiveis-brasil*
- Preço médio de revenda da gasolina comum
- Granularidade: **mensal**
- Cobertura: múltiplos anos
- Variável-alvo: preço do mês seguinte

Referencial Bibliográfico

Referência	Objetivo	Base de Dados	Métricas (melhores)
Wei et al. (2022) [1]	Propor modelo híbrido HARLSTM para previsão de preços de gasolina com seleção ótima de janela temporal	Preços semanais de gasolina (Florida, EUA) + fatores macroeconômicos	MSE: 0,008 MAE: 0,06 MAPE: 0,19%
Lazcano et al. (2024) [2]	Demonstrar que arquiteturas MLP simples superam modelos complexos (LSTM, Transformer) em séries temporais financeiras	Preços Brent, WTI e mercado elétrico espanhol (OMIE)	MSE e R ² superiores ao LSTM e Transformer em múltiplos datasets
Alwadi (2025) [3]	Comparar ARIMA, Regressão Linear, Árvore de Decisão, RF, GRU e LSTM para previsão de preço de combustível em tempo real	Registros de vendas de posto de gasolina na Jordânia (sistema online)	MSE: 1,41 R ² : 0,986 (RF)
Jin & Xu (2024) [4]	Aplicar redes neurais autorregressivas não-lineares (NARNN) para previsão de preços de energia (cru, gás, aquecimento)	WTI, Brent, heating oil, gás natural (dados diários históricos)	RRMSE < 2% (WTI/Brent); R ² > 0,91 em todos os ativos

Visão Geral da Metodologia

Pipeline geral



Configuração do modelo

- Arquitetura: Dense(36) → Dense(18) → Dense(8) → Dense(1)
- Ativação oculta: ReLU
- Saída: linear
- Loss: MSE

Treinamento

- Otimizador: Adam
- Batch size: 2
- Épocas: 200
- Normalização: MinMaxScaler [0, 1]
- Validação: 20% do treino

Estratégias de Representação Temporal

Abordagem 1 — Discretização

Ano e mês representados como **inteiros**. Entrada: $[\text{ano}, \text{mes}, p_t] \rightarrow$ saída: p_{t+1} . Simples, mas trata o tempo como grandeza linear contínua.

Abordagem 2 — Codificação Trigonométrica

Ano e mês codificados como $\sin(\text{ano})$ e $\sin(\text{mes})$. Entrada: $[\sin(\text{ano}), \sin(\text{mes}), p_t] \rightarrow$ saída: p_{t+1} . Captura periodicidade: mês 12 e mês 1 ficam próximos no espaço de entrada.

Abordagem 3 — Janelamento (*Windowing*)

Usa os n preços anteriores como entrada direta, sem codificação de data:

$$[p_{t-n+1}, \dots, p_{t-1}, p_t] \rightarrow p_{t+1}$$

Testado com $n = 2$ e $n = 4$. A rede aprende padrões de autocorrelação temporal.

Janelamento — Intuição e Implementação

O que é janelamento?

- Técnica clássica para séries temporais;
- Uma **janela deslizante** de n passos percorre a série
- Cada posição gera um exemplo de treino;
- Não precisa de features de data — o histórico de preços é a entrada.

Vantagem

A rede aprende padrões de tendência e autocorrelação diretamente dos valores passados, sem depender de representação explícita do tempo.

Exemplo com $n = 2$

p_{t-1}	p_t		p_{t+1}
5,10	5,25	→	5,38
5,25	5,38	→	5,41
5,38	5,41	→	5,60

Exemplo com $n = 4$

p_{t-3}	p_{t-2}	p_{t-1}	p_t	$\hat{p}_{t+1}$
5,10	5,25	5,38	5,41	5,60

Resultados: Comparação entre Abordagens

Tabela: Desempenho dos modelos no conjunto de teste

Abordagem	Entradas	MSE	MAE	R ²
Discretização	ano, mês, p_t	13,18%	29,48%	83,06%
Trigonométrica	$\cos(\text{mês})$, $\sin(\text{mês})$, p_t	13,44%	25,17%	82,72%
Janelamento $n = 2$	p_{t-1} , p_t	10,53%	22,11%	86,46%
Janelamento $n = 4$	p_{t-3} , p_{t-2} , p_{t-1} , p_t	9,85%	24,27%	89,09%
Janelamento $n = 10$	p_{t-3} , p_{t-2} , p_{t-1} , p_t	8,86%	24,43%	92,14%

Observação

MAE: média dos erros de previsão

MSE: penaliza erros grandes (eleva ao quadrado).


$\text{MSE} \approx \text{MAE} \rightarrow$ erros uniformes, sem outliers de previsão.

$\text{MSE} \gg \text{MAE} \rightarrow$ erros pontuais grandes puxando o MSE para cima.


R²: % da variação real o modelo acertou.

Resultados: Previsto vs. Real

Janelamento $n = 2$



Janelamento $n = 4$




Observação

Curvas de $n = 4$ tendem a suavizar melhor variações abruptas, pois a rede dispõe de mais contexto histórico. A comparação visual entre as duas janelas evidencia o impacto do tamanho da janela na capacidade de seguimento da série.

Resultados: Previsto vs. Real

Janelamento $n = 10$



Observação

A janela $n = 10$ apresenta o melhor R^2 (92,14%), indicando maior capacidade de capturar a tendência da série. A curva prevista acompanha o comportamento geral dos preços, com defasagem pontual nos picos — esperada em modelos que utilizam apenas o histórico de preços como entrada.

Comparação com a Literatura

Tabela: Comparação do R^2 entre este trabalho e trabalhos relacionados

Trabalho	Modelo	Domínio	R^2
Alwadi (2025) [3]	Random Forest	Combustível (Jordânia)	98,60%
Jin & Xu (2024) [4]	NARNN	Cru/gás (global, diário)	>91,00%
Este trabalho	MLP — Janelamento $n = 10$	Gasolina (Brasil, mensal)	92,14%
Este trabalho	MLP — Janelamento $n = 4$	Gasolina (Brasil, mensal)	89,09%
Este trabalho	MLP — Janelamento $n = 2$	Gasolina (Brasil, mensal)	86,46%

Observação

O modelo MLP com janelamento $n = 10$ alcança R^2 de 92,14%, resultado competitivo com trabalhos recentes que utilizam arquiteturas mais complexas, usando apenas o histórico de preços como entrada.

Discussão e Conclusão

Pontos fortes

- Janelamento elimina a necessidade de engenharia de features temporais;
- Janelas maiores capturam melhor a tendência da série, com melhora consistente do R^2 de 86,46% ($n = 2$) a 92,14% ($n = 10$);
- Pipeline simples e reproduzível, inteiramente em Python.

Limitações

- MLP não possui memória sequencial explícita (sem recorrência);
- Série temporal de preços sofre influência de fatores externos não modelados (câmbio, política de preços da Petrobras);
- Janelas maiores reduzem o número de exemplos de treino disponíveis.

Trabalhos futuros

- Experimentar arquiteturas recorrentes: **LSTM**;
- Ampliar o janelamento ($n = 12$) para capturar sazonalidade anual;
- Incorporar variáveis exógenas (câmbio, preço do barril de petróleo).

Referências I

- [1] Siyi Wei et al. “A Hybrid Autoregressive LSTM Model-based Gasoline Price Predicting Method Using Optimal Time Window”. Em: **Proceedings of the 3rd International Conference on Computer Engineering and Intelligent Control (ICCEIC 2022)**. Vol. 3344. CEUR Workshop Proceedings. 2022, pp. 53–61. URL: <https://ceur-ws.org/Vol-3344/paper08.pdf>.
- [2] Ana Lazcano, Miguel A. Jaramillo-Morán e Julio E. Sandubete. “Back to Basics: The Power of the Multilayer Perceptron in Financial Time Series Forecasting”. Em: **Mathematics** 12.12 (2024), p. 1920. DOI: 10.3390/math12121920.
- [3] Mohammad Abdulaziz Alwadi. “Fuel Sales Price Forecasting using Time Series, Machine Learning, and Deep Learning Models”. Em: **Engineering, Technology & Applied Science Research** 15.3 (2025), pp. 22360–22366. DOI: 10.48084/etasr.10348.

Referências II

- [4] Bohao Jin e Xiaoming Xu. “Price Forecasting through Neural Networks for Crude Oil, Heating Oil, and Natural Gas”. Em: **Energy Strategy Reviews** 53 (2024), p. 101370. DOI: 10.1016/j.esr.2024.101370.

Obrigado(a) pela Atenção!