

Clusterização de municípios brasileiros por perfil socioeconômico

Docente: Prof. Dr. Tiago Palma Pagano

Discentes: Carlos André Lima de Matos

Osvaldo Limeira Santos

Programa: Pós-Graduação em Engenharia Elétrica e
Computação (PGEEC)

Centro: Centro de Ciências Exatas e Tecnológicas (CETEC)

Instituição: Universidade Federal do Recôncavo da Bahia
(UFRB)

Sumário

1

Introdução

- Contexto e Justificativa
- Objetivos

2

Referencial

- Trabalhos Relacionados

3

Metodologia

- Dados socioeconômicos dos municípios
- Processamento e Espaço de Características

4

Resultados

- Determinação do Número de Clusters (K)
- Caracterização dos Perfis
- Comparação entre Algoritmos
- Análise dos Perfis

5

Conclusões

- Considerações Finais

Resumo

Este trabalho aplica **aprendizado de máquina não supervisionado** para agrupar os 5.571 municípios brasileiros segundo seu perfil socioeconômico. A partir de uma base com 39 indicadores oficiais (IBGE, IPEA e MDS), foram selecionadas 16 variáveis de porte, renda, saneamento, educação, saúde e estrutura produtiva. Quatro algoritmos (**K-Means**, hierárquico, **DBSCAN** e **Fuzzy C-Means**) foram comparados, com o número de grupos definido pelo método do cotovelo. Os resultados revelam uma estratificação socioeconômica de forte padrão territorial, que separa municípios desenvolvidos, agroindustriais e vulneráveis. O achado acompanha as desigualdades regionais já descritas na literatura.

Contexto e Justificativa

Heterogeneidade Regional

Os 5.571 municípios brasileiros diferem muito entre si em infraestrutura, renda, saúde e estrutura produtiva. Políticas públicas padronizadas costumam falhar quando ignoram as especificidades locais e as relações entre as várias dimensões do desenvolvimento.

Contexto e Justificativa

Heterogeneidade Regional

Os 5.571 municípios brasileiros diferem muito entre si em infraestrutura, renda, saúde e estrutura produtiva. Políticas públicas padronizadas costumam falhar quando ignoram as especificidades locais e as relações entre as várias dimensões do desenvolvimento.

Otimização de Recursos

Agrupar os municípios por perfil socioeconômico (agroindustrial, desenvolvido, vulnerável) dá base para alocar recursos onde eles rendem mais e para desenhar políticas públicas adequadas a cada realidade regional.

Contexto e Justificativa

Heterogeneidade Regional

Os 5.571 municípios brasileiros diferem muito entre si em infraestrutura, renda, saúde e estrutura produtiva. Políticas públicas padronizadas costumam falhar quando ignoram as especificidades locais e as relações entre as várias dimensões do desenvolvimento.

Otimização de Recursos

Agrupar os municípios por perfil socioeconômico (agroindustrial, desenvolvido, vulnerável) dá base para alocar recursos onde eles rendem mais e para desenhar políticas públicas adequadas a cada realidade regional.

Objetivos

Objetivo Geral

Identificar e classificar os municípios brasileiros em grupos distintos com base em suas características socioeconômicas, para entender melhor as disparidades regionais e apoiar a tomada de decisão pública.

Objetivos

Objetivo Geral

Identificar e classificar os municípios brasileiros em grupos distintos com base em suas características socioeconômicas, para entender melhor as disparidades regionais e apoiar a tomada de decisão pública.

Objetivos Específicos:

Objetivos

Objetivo Geral

Identificar e classificar os municípios brasileiros em grupos distintos com base em suas características socioeconômicas, para entender melhor as disparidades regionais e apoiar a tomada de decisão pública.

Objetivos Específicos:

- 1 Selecionar variáveis representativas de dimensões críticas, como porte demográfico, infraestrutura, saúde, educação e estrutura produtiva;

Objetivos

Objetivo Geral

Identificar e classificar os municípios brasileiros em grupos distintos com base em suas características socioeconômicas, para entender melhor as disparidades regionais e apoiar a tomada de decisão pública.

Objetivos Específicos:

- 1 Selecionar variáveis representativas de dimensões críticas, como porte demográfico, infraestrutura, saúde, educação e estrutura produtiva;
- 2 Avaliar a eficácia de diferentes algoritmos de aprendizado não supervisionado no agrupamento dos dados;

Objetivos

Objetivo Geral

Identificar e classificar os municípios brasileiros em grupos distintos com base em suas características socioeconômicas, para entender melhor as disparidades regionais e apoiar a tomada de decisão pública.

Objetivos Específicos:

- 1 Selecionar variáveis representativas de dimensões críticas, como porte demográfico, infraestrutura, saúde, educação e estrutura produtiva;
- 2 Avaliar a eficácia de diferentes algoritmos de aprendizado não supervisionado no agrupamento dos dados;
- 3 Definir uma taxonomia, ou perfil socioeconômico, para os municípios, consolidando os resultados encontrados pelos modelos.

Trabalhos Relacionados

Tipologias por análise fatorial e estratificação:



Trabalhos Relacionados

Tipologias por análise fatorial e estratificação:

- Calvo et al. (2016) e Willemann et al. (2019) estratificam os municípios brasileiros em grupos homogêneos por **análise fatorial** das condições demográficas, socioeconômicas e de saúde. Apontam densidade, urbanização, PIB per capita e pobreza como variáveis de maior peso, quase as mesmas adotadas aqui.

Trabalhos Relacionados

Tipologias por análise fatorial e estratificação:

- Calvo et al. (2016) e Willemann et al. (2019) estratificam os municípios brasileiros em grupos homogêneos por **análise fatorial** das condições demográficas, socioeconômicas e de saúde. Apontam densidade, urbanização, PIB per capita e pobreza como variáveis de maior peso, quase as mesmas adotadas aqui.

Agrupamento por clusterização:

Trabalhos Relacionados

Tipologias por análise fatorial e estratificação:

- Calvo et al. (2016) e Willemann et al. (2019) estratificam os municípios brasileiros em grupos homogêneos por **análise fatorial** das condições demográficas, socioeconômicas e de saúde. Apontam densidade, urbanização, PIB per capita e pobreza como variáveis de maior peso, quase as mesmas adotadas aqui.

Agrupamento por clusterização:

- Carvalho et al. (2007), em estudo do IPEA, aplicam **clusterização hierárquica espacial** e evidenciam forte padrão territorial das desigualdades Norte/Nordeste **vs.** Sul/Sudeste;

Trabalhos Relacionados

Tipologias por análise fatorial e estratificação:

- Calvo et al. (2016) e Willemann et al. (2019) estratificam os municípios brasileiros em grupos homogêneos por **análise fatorial** das condições demográficas, socioeconômicas e de saúde. Apontam densidade, urbanização, PIB per capita e pobreza como variáveis de maior peso, quase as mesmas adotadas aqui.

Agrupamento por clusterização:

- Carvalho et al. (2007), em estudo do IPEA, aplicam **clusterização hierárquica espacial** e evidenciam forte padrão territorial das desigualdades Norte/Nordeste **vs.** Sul/Sudeste;
- Dias et al. (2024) combinam **método hierárquico e K-Means** (com k definido pelo dendrograma) para tipificar os municípios de pequeno porte, a mesma estratégia metodológica deste trabalho.

Trabalhos Relacionados

Tipologias por análise fatorial e estratificação:

- Calvo et al. (2016) e Willemann et al. (2019) estratificam os municípios brasileiros em grupos homogêneos por **análise fatorial** das condições demográficas, socioeconômicas e de saúde. Apontam densidade, urbanização, PIB per capita e pobreza como variáveis de maior peso, quase as mesmas adotadas aqui.

Agrupamento por clusterização:

- Carvalho et al. (2007), em estudo do IPEA, aplicam **clusterização hierárquica espacial** e evidenciam forte padrão territorial das desigualdades Norte/Nordeste **vs.** Sul/Sudeste;
- Dias et al. (2024) combinam **método hierárquico e K-Means** (com k definido pelo dendrograma) para tipificar os municípios de pequeno porte, a mesma estratégia metodológica deste trabalho.

Lacuna: a literatura consolidou **quais** dimensões separam os municípios; este trabalho avança ao **comparar sistematicamente** K-Means, hierárquico, DBSCAN e Fuzzy C-Means sobre elas.

Dados: Perfil socioeconômico dos municípios

Base: O dataset foi construído a partir de uma base consolidada de 5.571 municípios brasileiros, integrando múltiplos índices oficiais (IBGE/SIDRA, IPEA/Atlas e MDS) para compor o perfil socioeconômico.

Tabela 1 – Amostra do dataset com variáveis representativas de contrastes regionais.

Município	UF	Renda pc (R\$)	Esgoto (%)	Alfab. (%)	Bolsa Fam. (% pop.)
São Paulo	SP	2 713,36	95,23	97,42	14,49
Salvador	BA	1 770,35	94,97	96,55	26,81
Medicilândia	PA	763,10	5,65	87,13	61,72


Fonte: Elaborado pelos autores (2026). Amostra de 4 das 39 variáveis coletadas.

A base final reúne indicadores de porte, renda, saneamento, educação, saúde, estrutura produtiva e vulnerabilidade social.

Dados: Correlação entre as variáveis

Base: O dataset foi construído a partir de uma base consolidada de 5.571 municípios brasileiros, integrando múltiplos índices oficiais para compor o perfil socioeconômico.

Figura 1 – Matriz de correlação entre as variáveis socioeconômicas selecionadas.



CETE

Centro de Ciências
Exatas e Tecnológicas

Fonte: Elaborado pelos autores (2026) a partir de dados consolidados do IBGE/IPEA.

Processamento e Espaço de Características



Tratamento de Assimetria

Variáveis de escala (População, PIB e Densidade) submetidas a transformação logarítmica ($\log_{10}$).

Redução da influência de outliers e correção da forte assimetria na distribuição dos dados municipais.

Normalização

Aplicação de StandardScaler para centralização dos dados (média=0, desvio-padrão=1).

Garantir que variáveis com escalas distintas (ex: Renda vs. Taxas percentuais) possuam pesos equivalentes no cálculo da distância.

Espaço de Características

Seleção de 16 variáveis a partir da base original de 39.

Espaço multidimensional focado em: porte, educação, saneamento, renda, estrutura produtiva e saúde.

Algoritmos de Agrupamento Aplicados

Tabela 2 – Algoritmos implementados e premissas.

Algoritmo	Abordagem	Principal característica
K-Means	Particional	Baseado em centroides (K-means++)
Hierárquico	Aglomerativo	Estrutura em dendrograma
DBSCAN	Densidade	Identificação de ruídos/outliers
Fuzzy C-Means	Soft	Pertencimento parcial aos clusters

Fonte: Elaborado pelos autores (2026).

Estratégia de Modelagem e Validação



Estratégia de Modelagem e Validação

- **Métricas de Distância:** Comparativo entre a distância Euclidiana (padrão) e de Mahalanobis para tratamento de variáveis correlacionadas;

Estratégia de Modelagem e Validação

- **Métricas de Distância:** Comparativo entre a distância Euclidiana (padrão) e de Mahalanobis para tratamento de variáveis correlacionadas;
- **Determinação de Clusters:** Aplicação do método do cotovelo (elbow method) via biblioteca kneed para seleção do número ideal de grupos, minimizando a inércia intra-cluster;


Estratégia de Modelagem e Validação

- **Métricas de Distância:** Comparativo entre a distância Euclidiana (padrão) e de Mahalanobis para tratamento de variáveis correlacionadas;
- **Determinação de Clusters:** Aplicação do método do cotovelo (elbow method) via biblioteca kneed para seleção do número ideal de grupos, minimizando a inércia intra-cluster;
- **Ambiente de Implementação:** Uso da biblioteca scikit-learn para algoritmos particionais e de densidade, e scikit-fuzzy para a lógica Fuzzy C-Means;

Nota: Parâmetros definidos via método do cotovelo para o dataset de 5.571 municípios.

Resultados: Determinação do Número de Clusters (K)


Figura 2 – Curva de Inércia (WCSS) para seleção de K.



Fonte: Elaborado pelos autores (2026).

Resultados: Determinação do Número de Clusters (K)

Figura 2 – Curva de Inércia (WCSS) para seleção de K.




Fonte: Elaborado pelos autores (2026).

- **Critério de Seleção:**
Identificação do ponto de inflexão (elbow point) na curva de inércia;

Resultados: Determinação do Número de Clusters (K)

Figura 2 – Curva de Inércia (WCSS) para seleção de K.



Fonte: Elaborado pelos autores (2026).

- **Critério de Seleção:** Identificação do ponto de inflexão (elbow point) na curva de inércia;
- **Valor Escolhido:** K = 3, ponto identificado como o cotovelo da curva. Separa bem os grupos e mantém a interpretabilidade, sem fragmentar demais a classificação;

Resultados: Caracterização dos Perfis (Clusters)


Tabela 3 – Algoritmos implementados e premissas.

Cluster	Perfil Predominante	Variável de Destaque
C1	Desenvolvidos	Renda e Saneamento
C2	Agroindustrial	PIB per capita e Urbanização
C3	Vulneráveis	Baixo IDH e Pobreza

Fonte: Elaborado pelos autores (2026).

Resultados: Comparação entre os Algoritmos


Figura 3 – Partições dos quatro algoritmos projetadas via PCA (2 componentes).



Fonte: Elaborado pelos autores (2026).

Resultados: Comparação entre os Algoritmos

Figura 3 – Partições dos quatro algoritmos projetadas via PCA (2 componentes).




Fonte: Elaborado pelos autores (2026).

- **K-Means:** separação nítida em 3 grupos, com centroides bem definidos;

Resultados: Comparação entre os Algoritmos

Figura 3 – Partições dos quatro algoritmos projetadas via PCA (2 componentes).




Fonte: Elaborado pelos autores (2026).

- **K-Means:** separação nítida em 3 grupos, com centroides bem definidos;
- **Hierárquico (médio):** sofre encadeamento, concentrando quase tudo em um grupo;

Resultados: Comparação entre os Algoritmos

Figura 3 – Partições dos quatro algoritmos projetadas via PCA (2 componentes).




Fonte: Elaborado pelos autores (2026).

- **K-Means:** separação nítida em 3 grupos, com centroides bem definidos;
- **Hierárquico (médio):** sofre encadeamento, concentrando quase tudo em um grupo;
- **DBSCAN:** trata os dados como **continuum** e rotula outliers como ruído;

Resultados: Comparação entre os Algoritmos

Figura 3 – Partições dos quatro algoritmos projetadas via PCA (2 componentes).




Fonte: Elaborado pelos autores (2026).

- **K-Means:** separação nítida em 3 grupos, com centroides bem definidos;
- **Hierárquico (médio):** sofre encadeamento, concentrando quase tudo em um grupo;
- **DBSCAN:** trata os dados como **continuum** e rotula outliers como ruído;
- **Fuzzy C-Means:** recupera a estrutura tripartite com fronteiras difusas.

Nota: Projecção em PC1 × PC2 apenas para visualização; a clusterização ocorre no espaço das 16 variáveis.

Resultados: Análise Espacial dos Perfis


Figura 4 – Distribuição espacial dos clusters identificados.



Fonte: Elaborado pelos autores (2026).

Resultados: Análise Espacial dos Perfis

Figura 4 – Distribuição espacial dos clusters identificados.




- **Estratificação Territorial:**
o modelo recupera as disparidades regionais históricas do país;

Fonte: Elaborado pelos autores (2026).

Resultados: Análise Espacial dos Perfis

Figura 4 – Distribuição espacial dos clusters identificados.




Fonte: Elaborado pelos autores (2026).

- **Estratificação Territorial:** o modelo recupera as disparidades regionais históricas do país;
- **Correlação Regional:** a vulnerabilidade se concentra no Norte e Nordeste, enquanto os polos de dinamismo econômico ficam no Sul e Sudeste;

Resultados: Análise Espacial dos Perfis

Figura 4 – Distribuição espacial dos clusters identificados.



Fonte: Elaborado pelos autores (2026).

- **Estratificação Territorial:** o modelo recupera as disparidades regionais históricas do país;
- **Correlação Regional:** a vulnerabilidade se concentra no Norte e Nordeste, enquanto os polos de dinamismo econômico ficam no Sul e Sudeste;
- **Validação do Modelo:** a distribuição espacial dos clusters coincide com os indicadores oficiais do IBGE, o que dá consistência ao agrupamento;

CETEC

Centro de Ciências
Exatas e Tecnológicas

Conclusões e Trabalhos Futuros

Conclusões

A clusterização revelou uma estratificação socioeconômica clara no território brasileiro, mais detalhada do que a leitura usual de desigualdades por macrorregião. O K-Means com $K=3$ separou três perfis: municípios vulneráveis, dinâmicos e agroindustriais. A coincidência entre esses grupos e a geografia conhecida das desigualdades reforça a validade da partição. A transformação logarítmica das variáveis de escala e a escolha de K pelo cotovelo sustentam a consistência estatística da divisão dos 5.571 municípios.

Conclusões e Trabalhos Futuros

Conclusões

A clusterização revelou uma estratificação socioeconômica clara no território brasileiro, mais detalhada do que a leitura usual de desigualdades por macrorregião. O K-Means com $K=3$ separou três perfis: municípios vulneráveis, dinâmicos e agroindustriais. A coincidência entre esses grupos e a geografia conhecida das desigualdades reforça a validade da partição. A transformação logarítmica das variáveis de escala e a escolha de K pelo cotovelo sustentam a consistência estatística da divisão dos 5.571 municípios.

Trabalhos futuros (possíveis caminhos):

Conclusões e Trabalhos Futuros

Conclusões

A clusterização revelou uma estratificação socioeconômica clara no território brasileiro, mais detalhada do que a leitura usual de desigualdades por macrorregião. O K-Means com $K=3$ separou três perfis: municípios vulneráveis, dinâmicos e agroindustriais. A coincidência entre esses grupos e a geografia conhecida das desigualdades reforça a validade da partição. A transformação logarítmica das variáveis de escala e a escolha de K pelo cotovelo sustentam a consistência estatística da divisão dos 5.571 municípios.

Trabalhos futuros (possíveis caminhos):

- **Análise Espacial:** integrar métodos de autocorrelação espacial (ex.: Moran's I) para quantificar a dependência geográfica entre os clusters;

Conclusões e Trabalhos Futuros

Conclusões

A clusterização revelou uma estratificação socioeconômica clara no território brasileiro, mais detalhada do que a leitura usual de desigualdades por macrorregião. O K-Means com $K=3$ separou três perfis: municípios vulneráveis, dinâmicos e agroindustriais. A coincidência entre esses grupos e a geografia conhecida das desigualdades reforça a validade da partição. A transformação logarítmica das variáveis de escala e a escolha de K pelo cotovelo sustentam a consistência estatística da divisão dos 5.571 municípios.

Trabalhos futuros (possíveis caminhos):

- **Análise Espacial:** integrar métodos de autocorrelação espacial (ex.: Moran's I) para quantificar a dependência geográfica entre os clusters;
- **Séries Temporais:** acompanhar a evolução dos perfis ao longo dos anos e a migração dos municípios entre grupos;

Conclusões e Trabalhos Futuros

Conclusões

A clusterização revelou uma estratificação socioeconômica clara no território brasileiro, mais detalhada do que a leitura usual de desigualdades por macrorregião. O K-Means com $K=3$ separou três perfis: municípios vulneráveis, dinâmicos e agroindustriais. A coincidência entre esses grupos e a geografia conhecida das desigualdades reforça a validade da partição. A transformação logarítmica das variáveis de escala e a escolha de K pelo cotovelo sustentam a consistência estatística da divisão dos 5.571 municípios.

Trabalhos futuros (possíveis caminhos):

- **Análise Espacial:** integrar métodos de autocorrelação espacial (ex.: Moran's I) para quantificar a dependência geográfica entre os clusters;
- **Séries Temporais:** acompanhar a evolução dos perfis ao longo dos anos e a migração dos municípios entre grupos;
- **Modelos Preditivos:** utilizar os perfis obtidos como input para prever a demanda por políticas públicas específicas em cada cluster;

Conclusões e Trabalhos Futuros

Conclusões

A clusterização revelou uma estratificação socioeconômica clara no território brasileiro, mais detalhada do que a leitura usual de desigualdades por macrorregião. O K-Means com $K=3$ separou três perfis: municípios vulneráveis, dinâmicos e agroindustriais. A coincidência entre esses grupos e a geografia conhecida das desigualdades reforça a validade da partição. A transformação logarítmica das variáveis de escala e a escolha de K pelo cotovelo sustentam a consistência estatística da divisão dos 5.571 municípios.

Trabalhos futuros (possíveis caminhos):

- **Análise Espacial:** integrar métodos de autocorrelação espacial (ex.: Moran's I) para quantificar a dependência geográfica entre os clusters;
- **Séries Temporais:** acompanhar a evolução dos perfis ao longo dos anos e a migração dos municípios entre grupos;
- **Modelos Preditivos:** utilizar os perfis obtidos como input para prever a demanda por políticas públicas específicas em cada cluster;
- **Abordagens Híbridas:** explorar o refinamento dos grupos via algoritmos de densidade (DBSCAN) ou lógica Fuzzy para tratar municípios em zonas de transição.



Obrigado pela atenção!

Perguntas e comentários são bem-vindos.

Referências I

-  Calvo, Maria Cristina Marino et al. (2016). “Estratificação de municípios brasileiros para avaliação de desempenho em saúde”. Em: **Epidemiologia e Serviços de Saúde** 25.4, pp. 767–776. DOI: 10.5123/S1679-49742016000400010.
-  Carvalho, Alexandre Xavier Ywata de, Daniel Da Mata e Guilherme Mendes Resende (2007). “Clusterização dos municípios brasileiros”. Em: **Dinâmica dos municípios**. Ed. por João Alberto De Negri e Daniel Da Mata. Brasília: IPEA, pp. 181–206.
-  Dias, João Marcos Nogueira, Pedro Vasconcelos Amaral e Leandro Luz (2024). “Características socioeconômicas e tipologia dos municípios de pequeno porte no Brasil”. Em: **Nova Economia** 34.2, pp. 1–31. DOI: 10.1590/0103-6351/8161.
-  Willemann, Maria Cristina Antunes et al. (2019). “Atualização intercensitária de estratificação de municípios brasileiros para avaliação de desempenho em saúde, 2015”. Em: **Epidemiologia e Serviços de Saúde** 28.3, e2018377. DOI: 10.5123/S1679-49742019000300050.