

Previsão de Séries Temporais do Preço Médio de Revenda da Gasolina com Redes Neurais Artificiais

Multilayer Perceptrons aplicadas à previsão de curto prazo do preço da gasolina comum no Brasil (2001–2023)

Docente: Prof. Dr. Tiago Palma Pagano

Discentes: Carlos André Lima de Matos
Osvaldo Limeira Santos

Programa: Pós-Graduação em Engenharia Elétrica e Computação (PGEEC)

Centro: Centro de Ciências Exatas e Tecnológicas (CETEC)

Instituição: Universidade Federal do Recôncavo da Bahia (UFRB)

Sumário

1

Introdução

- Contexto e Justificativa
- Objetivos

2

Referencial

- Trabalhos Relacionados

3

Metodologia

- Dados e Série Temporal

- Representações de Entrada
- Arquitetura da Rede

4

Resultados

- Baseline e Modelos
- Comparação visual e curvas

5

Conclusões

- Considerações Finais

Contexto e Justificativa

Por que prever o preço da gasolina?

- O preço afeta diretamente a inflação e o custo do transporte;
- A série tem forte volatilidade e tendência de alta ao longo dos anos.

Contexto e Justificativa

Por que prever o preço da gasolina?

- O preço afeta diretamente a inflação e o custo do transporte;
- A série tem forte volatilidade e tendência de alta ao longo dos anos.

Por que Redes Neurais Artificiais (RNA)?

- Reconhecem padrões e ajustam relações não-lineares (Rumelhart et al., 1986);
- Já foram usadas para prever séries energéticas de curto prazo no Brasil (Zucatelli et al., 2018; Zucatelli et al., 2019).

Contexto e Justificativa

Por que prever o preço da gasolina?

- O preço afeta diretamente a inflação e o custo do transporte;
- A série tem forte volatilidade e tendência de alta ao longo dos anos.

Por que Redes Neurais Artificiais (RNA)?

- Reconhecem padrões e ajustam relações não-lineares (Rumelhart et al., 1986);
- Já foram usadas para prever séries energéticas de curto prazo no Brasil (Zucatelli et al., 2018; Zucatelli et al., 2019).

Objetivos

Objetivo Geral

Prever o **preço médio de revenda da gasolina comum** um mês à frente com redes **Multilayer Perceptron**, comparando diferentes formas de representar a entrada.

Objetivos

Objetivo Geral

Prever o **preço médio de revenda da gasolina comum** um mês à frente com redes **Multilayer Perceptron**, comparando diferentes formas de representar a entrada.

Objetivos Específicos:

Objetivos

Objetivo Geral

Prever o **preço médio de revenda da gasolina comum** um mês à frente com redes **Multilayer Perceptron**, comparando diferentes formas de representar a entrada.

Objetivos Específicos:

- 1 Aplicar e comparar **três** representações de entrada: $N=1$, discretização trigonométrica e janelamento;

Objetivos

Objetivo Geral

Prever o **preço médio de revenda da gasolina comum** um mês à frente com redes **Multilayer Perceptron**, comparando diferentes formas de representar a entrada.

Objetivos Específicos:

- 1 Aplicar e comparar **três** representações de entrada: $N=1$, discretização trigonométrica e janelamento;
- 2 Avaliar cada modelo por **MAE**, **MSE**, R^2 e correlação r ;

Objetivos

Objetivo Geral

Prever o **preço médio de revenda da gasolina comum** um mês à frente com redes **Multilayer Perceptron**, comparando diferentes formas de representar a entrada.

Objetivos Específicos:

- 1 Aplicar e comparar **três** representações de entrada: $N=1$, discretização trigonométrica e janelamento;
- 2 Avaliar cada modelo por **MAE**, **MSE**, R^2 e correlação r ;
- 3 Comparar as MLPs com um **baseline** de regressão linear;

Objetivos

Objetivo Geral

Prever o **preço médio de revenda da gasolina comum** um mês à frente com redes **Multilayer Perceptron**, comparando diferentes formas de representar a entrada.

Objetivos Específicos:

- 1 Aplicar e comparar **três** representações de entrada: $N=1$, discretização trigonométrica e janelamento;
- 2 Avaliar cada modelo por **MAE**, **MSE**, R^2 e correlação r ;
- 3 Comparar as MLPs com um **baseline** de regressão linear;
- 4 Apontar limitações e caminhos para melhorar os resultados.

Trabalhos Relacionados

Molde metodológico (RNA/MLP para previsão de curto prazo):

- Zucatelli et al. (2018) testam 7 arquiteturas MLP para prever a velocidade do vento em 1 h, com as mesmas métricas adotadas aqui (MAE, MSE, r e R^2);
- Zucatelli et al. (2021) e Nascimento et al. (2023) ampliam essa linha com **wavelet** e redes profundas.

Trabalhos Relacionados

Molde metodológico (RNA/MLP para previsão de curto prazo):

- Zucatelli et al. (2018) testam 7 arquiteturas MLP para prever a velocidade do vento em 1 h, com as mesmas métricas adotadas aqui (MAE, MSE, r e R^2);
- Zucatelli et al. (2021) e Nascimento et al. (2023) ampliam essa linha com **wavelet** e redes profundas.

Aplicação a preço de combustível:

- Jin e Xu (2024) aplicam redes neurais ao petróleo, óleo de aquecimento e gás natural;
- Eliwa et al. (2024) preveem o preço da gasolina com modelos neuro-**fuzzy**, enquanto Lazcano et al. (2024) defendem a MLP como **baseline** forte.

Trabalhos Relacionados

Molde metodológico (RNA/MLP para previsão de curto prazo):

- Zucatelli et al. (2018) testam 7 arquiteturas MLP para prever a velocidade do vento em 1 h, com as mesmas métricas adotadas aqui (MAE, MSE, r e R^2);
- Zucatelli et al. (2021) e Nascimento et al. (2023) ampliam essa linha com **wavelet** e redes profundas.


Aplicação a preço de combustível:

- Jin e Xu (2024) aplicam redes neurais ao petróleo, óleo de aquecimento e gás natural;
- Eliwa et al. (2024) preveem o preço da gasolina com modelos neuro-**fuzzy**, enquanto Lazcano et al. (2024) defendem a MLP como **baseline** forte.

Dados: Preço médio de revenda da gasolina

Base: série mensal do preço médio de revenda da gasolina comum (ANP), **jul/2001 a jan/2023** (257 observações).

Figura 1 – Série temporal do preço médio com a média do período.



Fonte: Elaborado pelos autores (2026) a partir de dados da ANP.¹

CETEC¹ Dados disponíveis em: <https://www.kaggle.com/datasets/fidelissauro/combustiveis-brasil/data>.

Três Representações de Entrada

N = 1

Entradas: ano, mês e o valor do mês atual.

Alvo: valor do próximo mês.

Disc. Trigonométrica

Entradas: $\sin(\text{mês})$, $\sin(\text{ano})$ e o valor atual.

Codifica o caráter cíclico do tempo.

Janelamento

Entradas: os N valores passados (janela = 3).
Abordagem autorregressiva.


Arquitetura da MLP Modelada

Tabela 1 – Configuração da MLP utilizada.

Componente	Valor
Camada de entrada	3 (N=1, Trig.) / 3 (janela)
1ª camada oculta	56 neurônios (ReLU)
2ª camada oculta	20 neurônios (ReLU)
Camada de saída	1 neurônio (linear)
Otimizador	Adam (Kingma e Ba, 2015)
Taxa de aprendizado	0,0005
Função de perda	MSE
Batch / Épocas	2 / 400

Fonte: Elaborado pelos autores (2026).
Configuração obtida por busca de hiperparâmetros.

Estrutura da rede



Feed-forward densa (ReLU nas ocultas, linear na saída), treinada por **backpropagation**.

Resultados dos Três Métodos e do **Baseline**

Tabela 2 – Métricas no conjunto de teste: três MLPs e **baseline** linear.


Modelo	R^2	MAE	MSE	r
N = 1	0,8590	0,0334	0,0029	0,9302
Discretização Trig.	0,8263	0,0388	0,0033	0,9216
Janelamento	0,8336	0,0404	0,0040	0,9341
Baseline (Reg. Linear)	0,8640	0,2122	0,0982	0,9349

Fonte: Elaborado pelos autores (2026).

- As três MLPs ficam com R^2 entre **0,83 e 0,86** e r acima de 0,92;
- No erro absoluto (MAE e MSE), as redes ficam bem à frente do **baseline**;
- A melhor rede foi a **N=1**, com o menor MAE e MSE e o maior R^2 entre elas.


Comparação: Previsto **vs.** Real e Curvas de Treino

Figura 2 – N=1: previsto **vs.** real no conjunto de teste.



Fonte: Elaborado pelos autores (2026).

Figura 3 – N=1: MSE de treino e validação ao longo das épocas.



Fonte: Elaborado pelos autores (2026).

Conclusões e Trabalhos Futuros

Conclusões

As três MLPs preveem bem o preço da gasolina no mês seguinte, com R^2 entre 0,83 e 0,86. A representação **N=1** foi a melhor entre as redes e ficou à frente do **baseline** linear em MAE e MSE. Em R^2 , porém, a regressão linear ainda empata com as redes (0,864 contra 0,859). Como a série é fortemente autorregressiva, o modelo linear continua sendo um **benchmark** difícil de superar.

Conclusões e Trabalhos Futuros

Conclusões

As três MLPs preveem bem o preço da gasolina no mês seguinte, com R^2 entre 0,83 e 0,86. A representação **N=1** foi a melhor entre as redes e ficou à frente do **baseline** linear em MAE e MSE. Em R^2 , porém, a regressão linear ainda empata com as redes (0,864 contra 0,859). Como a série é fortemente autorregressiva, o modelo linear continua sendo um **benchmark** difícil de superar.

Trabalhos futuros (possíveis caminhos):

Conclusões e Trabalhos Futuros

Conclusões

As três MLPs preveem bem o preço da gasolina no mês seguinte, com R^2 entre 0,83 e 0,86. A representação **N=1** foi a melhor entre as redes e ficou à frente do **baseline** linear em MAE e MSE. Em R^2 , porém, a regressão linear ainda empata com as redes (0,864 contra 0,859). Como a série é fortemente autorregressiva, o modelo linear continua sendo um **benchmark** difícil de superar.

Trabalhos futuros (possíveis caminhos):

- **Modelos estatísticos clássicos:** comparar com ARIMA, ARMA e modelos autorregressivos (Box e Jenkins, 1976);

Conclusões e Trabalhos Futuros

Conclusões

As três MLPs preveem bem o preço da gasolina no mês seguinte, com R^2 entre 0,83 e 0,86. A representação **N=1** foi a melhor entre as redes e ficou à frente do **baseline** linear em MAE e MSE. Em R^2 , porém, a regressão linear ainda empata com as redes (0,864 contra 0,859). Como a série é fortemente autorregressiva, o modelo linear continua sendo um **benchmark** difícil de superar.

Trabalhos futuros (possíveis caminhos):

- **Modelos estatísticos clássicos**: comparar com ARIMA, ARMA e modelos autorregressivos (Box e Jenkins, 1976);
- **Modelos recorrentes**: testar **LSTM** e GRU, projetados para dependências temporais longas (Hochreiter e Schmidhuber, 1997);

Conclusões e Trabalhos Futuros

Conclusões

As três MLPs preveem bem o preço da gasolina no mês seguinte, com R^2 entre 0,83 e 0,86. A representação **N=1** foi a melhor entre as redes e ficou à frente do **baseline** linear em MAE e MSE. Em R^2 , porém, a regressão linear ainda empata com as redes (0,864 contra 0,859). Como a série é fortemente autorregressiva, o modelo linear continua sendo um **benchmark** difícil de superar.

Trabalhos futuros (possíveis caminhos):

- **Modelos estatísticos clássicos**: comparar com ARIMA, ARMA e modelos autorregressivos (Box e Jenkins, 1976);
- **Modelos recorrentes**: testar **LSTM** e GRU, projetados para dependências temporais longas (Hochreiter e Schmidhuber, 1997);
- **Variáveis exógenas**: incluir câmbio e preço do petróleo (Brent), que influenciam o preço final;

Conclusões e Trabalhos Futuros

Conclusões

As três MLPs preveem bem o preço da gasolina no mês seguinte, com R^2 entre 0,83 e 0,86. A representação **N=1** foi a melhor entre as redes e ficou à frente do **baseline** linear em MAE e MSE. Em R^2 , porém, a regressão linear ainda empata com as redes (0,864 contra 0,859). Como a série é fortemente autorregressiva, o modelo linear continua sendo um **benchmark** difícil de superar.

Trabalhos futuros (possíveis caminhos):

- **Modelos estatísticos clássicos**: comparar com ARIMA, ARMA e modelos autorregressivos (Box e Jenkins, 1976);
- **Modelos recorrentes**: testar **LSTM** e GRU, projetados para dependências temporais longas (Hochreiter e Schmidhuber, 1997);
- **Variáveis exógenas**: incluir câmbio e preço do petróleo (Brent), que influenciam o preço final;
- **Pré-processamento**: investigar decomposição **wavelet**, que ajudou em séries longas na literatura (Zucatelli et al., 2021; Saghi e Jahangoshai Rezaee, 2023), embora em testes preliminares nesta série curta não tenha superado o **baseline**;

Conclusões e Trabalhos Futuros

Conclusões

As três MLPs preveem bem o preço da gasolina no mês seguinte, com R^2 entre 0,83 e 0,86. A representação **N=1** foi a melhor entre as redes e ficou à frente do **baseline** linear em MAE e MSE. Em R^2 , porém, a regressão linear ainda empata com as redes (0,864 contra 0,859). Como a série é fortemente autorregressiva, o modelo linear continua sendo um **benchmark** difícil de superar.

Trabalhos futuros (possíveis caminhos):

- **Modelos estatísticos clássicos**: comparar com ARIMA, ARMA e modelos autorregressivos (Box e Jenkins, 1976);
- **Modelos recorrentes**: testar **LSTM** e GRU, projetados para dependências temporais longas (Hochreiter e Schmidhuber, 1997);
- **Variáveis exógenas**: incluir câmbio e preço do petróleo (Brent), que influenciam o preço final;
- **Pré-processamento**: investigar decomposição **wavelet**, que ajudou em séries longas na literatura (Zucatelli et al., 2021; Saghi e Jahangoshai Rezaee, 2023), embora em testes preliminares nesta série curta não tenha superado o **baseline**;
- Avaliar outros modelos (XGBoost, **Random Forest**) e ampliar a busca de hiperparâmetros (Bergstra e Bengio, 2012).



Obrigado pela atenção!

Perguntas e comentários são bem-vindos.

Referências I

-  Bergstra, James e Yoshua Bengio (2012). “Random Search for Hyper-Parameter Optimization”. Em: **Journal of Machine Learning Research** 13, pp. 281–305.
-  Box, George E. P. e Gwilym M. Jenkins (1976). **Time Series Analysis: Forecasting and Control**. Holden-Day.
-  Eliwa, Eatedal A. et al. (2024). “Optimal gasoline price predictions: Leveraging the ANFIS regression model”. Em: **International Journal of Intelligent Systems** 2024, p. 8462056. DOI: 10.1155/2024/8462056.
-  Hochreiter, Sepp e Jürgen Schmidhuber (1997). “Long Short-Term Memory”. Em: **Neural Computation** 9.8, pp. 1735–1780. DOI: 10.1162/neco.1997.9.8.1735.
-  Jin, Jionghao e Yun Xu (2024). “Price forecasting through neural networks for crude oil, heating oil, and natural gas”. Em: **Measurement: Energy** 1, p. 100001. DOI: 10.1016/j.meae.2024.100001.

Referências II

-  Kingma, Diederik P. e Jimmy Ba (2015). “Adam: A Method for Stochastic Optimization”. Em: **3rd International Conference on Learning Representations (ICLR)**.
-  Lazcano, Ana, Miguel A. Jaramillo-Morán e Julio E. Sandubete (2024). “Back to Basics: The Power of the Multilayer Perceptron in Financial Time Series Forecasting”. Em: **Mathematics** 12.12, p. 1920. DOI: 10.3390/math12121920.
-  Nascimento, Erick Giovani Sperandio, Talison A. C. de Melo e Davidson Martins Moreira (2023). “A transformer-based deep neural network with wavelet transform for forecasting wind speed and wind energy”. Em: **Energy** 278, p. 127678. DOI: 10.1016/j.energy.2023.127678.
-  Rumelhart, David E., Geoffrey E. Hinton e Ronald J. Williams (1986). “Learning Representations by Back-Propagating Errors”. Em: **Nature** 323, pp. 533–536.

Referências III

-  Saghi, Faezeh e Mustafa Jahangoshai Rezaee (2023). “Integrating wavelet decomposition and fuzzy transformation for improving the accuracy of forecasting crude oil price”. Em: **Computational Economics** 61.2, pp. 559–591. DOI: 10.1007/s10614-021-10219-1.
-  Zucatelli, Pedro Junior et al. (2018). “Previsão da velocidade do vento a curto prazo usando redes neurais artificiais em Mucuri, Bahia”. Em: **X Congresso Nacional de Engenharia Mecânica (CONEM)**. Salvador, BA.
-  Zucatelli, Pedro Junior et al. (2019). “Short-term wind speed forecasting in Uruguay using computational intelligence”. Em: **Heliyon** 5.5, e01664. DOI: 10.1016/j.heliyon.2019.e01664.
-  Zucatelli, Pedro Junior et al. (2021). “An investigation on deep learning and wavelet transform to nowcast wind power and wind power ramp: A case study in Brazil and Uruguay”. Em: **Energy** 230, p. 120842. DOI: 10.1016/j.energy.2021.120842.